

Case-Study zur Arbeitslosigkeit in Deutschland

Organisatorische Hinweise

- ✚ Bis zum 08.05.2023 ist das 5. R-Tutor Problem Set auf Moodle hochzuladen (nur die .sub-Datei!)
- ✚ Bis zum 15.05.2023 ist das 6. R-Tutor Problem Set auf Moodle hochzuladen (nur die .sub-Datei!)
- ✚ Am 19.05.2023 findet die Probeklausur in Präsenz im Hörsaal H14 statt: Beginn 10:15 Uhr

Recap der Vorlesungsinhalte

- + Wir hatten die Wahrscheinlichkeitstheorie und die Normalverteilung besprochen
- + Wir hatten über die Stichprobenvarianz, Standardfehler und Konfidenzintervalle gesprochen
- + Wir hatten einen Hypothesentest durchgeführt
- + Wir hatten die Korrelation von zwei Variablen und die lineare Regression betrachtet
- + Anschließend sind wir in der multiplen linearen Regression auch auf Interaktionsterme eingegangen

Empirische Analyse unserer Case- Study

Induktive Statistik

- + Interesse gilt nicht dem Datensatz selbst, sondern der Population
 - + Sie haben keine Vollerhebung durchgeführt, sondern nur eine (zufällige) Stichprobe der Population gezogen
- + **Beispiel:** Mikrozensus, d.h. eine Befragung von zufällig ausgewählten Haushalten in Deutschland
- + Sie wollen aus der Stichprobe schätzen, wie sich die beobachtete Größe in der Population verhält
- + Es gibt viele Arten der induktiven Statistik. Die zwei häufigsten:
 - + Vorhersage
 - + Erkennen kausaler Zusammenhänge

Bereiche der induktiven Statistik

- + Stichprobentheorie
 - + Güte der Stichprobe; Wichtig um repräsentative Ergebnisse zu erhalten
- + Schätztheorie
 - + Punktschätzer und Konfidenzintervalle
- + Testtheorie
 - + Hypothesentest, lineare Regression

Wie sieht die induktive Statistik in der
Praxis aus?

Dritter Teil der Case Study

Daten aus der Case-Study, welche wir im vorherigen Semester eingelesen und deskriptiv analysiert haben wollen wir nun mittels der induktiven Statistik näher untersuchen.

- + Erster Schritt: Kurzer Recap mittels bivariater deskriptiver Statistik um den Zusammenhang verschiedener Variablen darzustellen
- + Zweiter Schritt: (Multiple) lineare Regression der Daten um herauszufinden, welche Faktoren die Arbeitslosenquote in den deutschen Landkreisen treibt
 - + Darstellung mit dem Paket `stargazer`

Dritter Teil der Case Study

Daten aus der Case-Study, welche wir im vorherigen Semester eingelesen und deskriptiv analysiert haben wollen wir nun mittels der induktiven Statistik näher untersuchen.

- + Erster Schritt: Kurzer Recap mittels bivariater deskriptiver Statistik um den Zusammenhang verschiedener Variablen darzustellen
- + Zweiter Schritt: (Multiple) lineare Regression der Daten um herauszufinden, welche Faktoren die Arbeitslosenquote in den deutschen Landkreisen treibt
 - + Darstellung mit dem Paket `stargazer`

Ziele des dritten Teils der Case Study:

- + (Multiple) lineare Regression und Interpretation der Koeffizienten
- + Interaktionsterme
- + Besprechen der Kausalität

Dritter Teil der Case Study

Daten aus der Case-Study, welche wir im vorherigen Semester eingelesen und deskriptiv analysiert haben wollen wir nun mittels der induktiven Statistik näher untersuchen.

- + Erster Schritt: Kurzer Recap mittels bivariater deskriptiver Statistik um den Zusammenhang verschiedener Variablen darzustellen
- + Zweiter Schritt: (Multiple) lineare Regression der Daten um herauszufinden, welche Faktoren die Arbeitslosenquote in den deutschen Landkreisen treibt
 - + Darstellung mit dem Paket `stargazer`

Ziele des dritten Teils der Case Study:

- + (Multiple) lineare Regression und Interpretation der Koeffizienten
- + Interaktionsterme
- + Besprechen der Kausalität

Im vierten RTutor Problem Set beschäftigen Sie sich auch mit der linearen Regression zu einzelnen Ländern auf europäischer Ebene und im 5. und 6. Problem Set geht es um die Kausalität.

Daten und Pakete laden

Wir laden die aus Teil 1 der Case-Study erstellten Datensätze:

```
library(tidyverse)
library(stargazer)
library(corr)

```

```
# Daten einlesen
bip_zeitreihe <- readRDS("../case-study/data/bip_zeitreihe.rds")
gesamtdaten <- readRDS("../case-study/data/gesamtdaten.rds")

# Zuerst wollen wir die Arbeitslosenquote, einen Dummy für Ostdeutschland und die Verschuldung im Verhältnis zum BIP pro Landkreis berechnen
gesamtdaten <- gesamtdaten %>%
  mutate(alo_quote = (total_alo / (erw+total_alo))*100,
         ost = as.factor(ifelse(bundesland_name %in% c("Brandenburg", "Mecklenburg-Vorpommern", "Sachsen", "Sachsen-Anhalt", "Thüringen"), 1, 0)),
         ost_name = ifelse(ost == 1, "Ostdeutschland", "Westdeutschland"),
         anteil_schulden = (Schulden_gesamt / bip)*100)

bip_wachstum <- bip_zeitreihe %>%
  filter( nchar(Regionalschlüssel) == 5 ) %>%
  group_by(Regionalschlüssel) %>%
  arrange(Jahr) %>%
  mutate( bip_wachstum = 100*(bip - lag(bip)) / bip ) %>%
  ungroup() %>%
  filter( Jahr == 2017 ) %>%
  select(Regionalschlüssel, bip_wachstum, Jahr)

gesamtdaten <- left_join(gesamtdaten, bip_wachstum, by = "Regionalschlüssel")

```

Bivariate deskriptive Analysen (Korrelationen)

Korrelation zwischen den einzelnen Variablen

Wir hatten uns im letzten Semester bereits die Korrelation der einzelnen Variablen angeschaut und wollen diese Korrelationen noch einmal aufgreifen:

Korrelation zwischen den einzelnen Variablen

Wir hatten uns im letzten Semester bereits die Korrelation der einzelnen Variablen angeschaut und wollen diese Korrelationen noch einmal aufgreifen:

Bevor wir uns der Regressionsanalyse zuwenden schauen wir uns den Zusammenhang der unterschiedlichen Variablen erst visuell noch einmal an.

- ✚ Wie hoch ist die Korrelation zwischen Arbeitslosenquote und BIP Wachstum?
- ✚ Wie hoch ist sie zwischen Arbeitslosenquote und dem Anteil der Schulden?
- ✚ Und schlussendlich: Wie hoch ist die Korrelation zwischen dem BIP Wachstum und dem Anteil der Schulden?

Korrelation zwischen den einzelnen Variablen

Wir hatten uns im letzten Semester bereits die Korrelation der einzelnen Variablen angeschaut und wollen diese Korrelationen noch einmal aufgreifen:


Bevor wir uns der Regressionsanalyse zuwenden schauen wir uns den Zusammenhang der unterschiedlichen Variablen erst visuell noch einmal an.

- + Wie hoch ist die Korrelation zwischen Arbeitslosenquote und BIP Wachstum?
- + Wie hoch ist sie zwischen Arbeitslosenquote und dem Anteil der Schulden?
- + Und schlussendlich: Wie hoch ist die Korrelation zwischen dem BIP Wachstum und dem Anteil der Schulden?

Hierdurch bekommen wir einen ersten Eindruck der Daten und werden auf mögliche Probleme aufmerksam, wie z.B. Multikollinearität.

Korrelation zwischen der Arbeitslosenquote und dem BIP Wachstum

```
cor_alo_bip <- cor(gesamtdaten$alo_quote,  
  gesamtdaten$bip_wachstum,  
  use = "pairwise.complete.obs")  
  
gesamtdaten %>%  
  ggplot(aes(x = bip_wachstum, y = alo_quote)) +  
  geom_point() +  
  labs(x = "Wachstum des BIP %",  
    y = "Arbeitslosenquote in %",  
    title = "Korrelation des BIP-Wachstums und  
  theme_minimal() +  
  geom_text(x = 0.02, y = 13, label = paste("r = ",
```




Korrelation zwischen der Arbeitslosenquote und dem Anteil der Schulden

```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote,  
  
gesamtdaten %>%  
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +  
  geom_point() +  
  labs( x = "Anteil der Schulden am BIP in %",  
        y = "Arbeitslosenquote in %",  
        title = "Korrelation der öffentlichen Verschuldung mit der Arbeitslosenquote")  
theme_minimal() +  
geom_text(x = 0.02, y = 13, label = paste("r = ",
```

Korrelation zwischen der Arbeitslosenquote und dem Anteil der Schulden

```
cor_alo_verschuldung <- cor(gesamtdaten$alo_quote,  
  
gesamtdaten %>%  
  ggplot(aes(x = anteil_schulden, y = alo_quote)) +  
  geom_point() +  
  labs(x = "Anteil der Schulden am BIP in %",  
       y = "Arbeitslosenquote in %",  
       title = "Korrelation der öffentlichen Verschuldung und der Arbeitslosenquote") +  
  theme_minimal() +  
  geom_text(x = 0.02, y = 13, label = paste("r = ",
```



Korrelationsmatrix

```
korrelationen <- gesamtdaten %>%  
  select(bip_wachstum, anteil_schulden, alo_quote) %>%  
  correlate() %>% # Korrelationen erzeugen  
  rearrange() %>% # Sortieren nach Korrelation  
  shave() # Oberen Teil der Tabelle abschneiden  
  
fashion(korrelationen)
```

```
##           term bip_wachstum alo_quote anteil_schulden  
## 1    bip_wachstum  
## 2      alo_quote      -.09  
## 3 anteil_schulden      -.14      .59
```

Interpretation der Korrelation

- + Hat an sich keine intuitive quantitative Interpretation
- + Ist eine univariate Repräsentation des Zusammenhangs zweier Variablen
- + Kann dabei helfen stark korrelierte Variablen im Datensatz aufzuzeigen
 - + Dies ist für eine spätere lineare Regression wichtig
 - + Stichwort Multikollinearität

Interpretation der Korrelation

- + Hat an sich keine intuitive quantitative Interpretation
- + Ist eine univariate Repräsentation des Zusammenhangs zweier Variablen
- + Kann dabei helfen stark korrelierte Variablen im Datensatz aufzuzeigen
 - + Dies ist für eine spätere lineare Regression wichtig
 - + Stichwort Multikollinearität

In empirischen Arbeiten wird meist auf die lineare Regression zurückgegriffen und nicht auf die Analyse von Korrelationen:

- + Schätzer aus der linearen Regression sind BLUE (best linear unbiased estimator)
- + Wir können auf mehrere Variablen kontrollieren in der linearen Regression

Einfache lineare Regression

Lineare Regression

Zur weiteren Analyse wollen wir uns der linearen Regression bedienen:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1, \dots, N$$

Wobei wir die Arbeitslosenquote (y_i) auf das BIP Wachstum (x_i) regressieren.

Arbeitslosenquote auf das BIP Wachstum regressieren

```
bip <- lm(alo_quote ~ bip_wachstum, data = gesamtdaten)

stargazer(bip,
  type = "html", header = FALSE, digits = 2,
  title = "Arbeitslosigkeit auf BIP-Wachstum",
  dep.var.labels=c("Alo-quote"),
  covariate.labels="BIP-Wachstum"
)
```


Arbeitslosenquote auf das BIP Wachstum regressieren

Arbeitslosigkeit auf BIP-Wachstum	
	<i>Dependent variable:</i>
	Alo-quote
BIP-Wachstum	-0.09 [*] (0.05)
Constant	5.68 ^{***} (0.23)
Observations	399
R ²	0.01
Adjusted R ²	0.005
Residual Std. Error	2.38 (df = 397)
F Statistic	2.98 [*] (df = 1; 397)
Note: [*] p<0.1; ^{**} p<0.05; ^{***} p<0.01	

Erkenntnisse aus der Regressionstabelle

- + 399 Beobachtungen
- + R^2 mit 0.01 recht klein
 - + R^2 kann künstlich nach oben getrieben werden, darum besser *adjusted* R^2 anschauen
- + R^2 ist irrelevant wenn wir unsere Schätzer kausal interpretieren wollen
 - + R^2 misst die Variation in y , diese wollen wir aber gar nicht erklären, sondern ob x einen kausalen Einfluss auf y hat!
- + R^2 ist wichtiger bei Vorhersagen
 - + Bei Vorhersagen möchten wir nach Möglichkeit y so gut es geht erklären.
- + Bei Zeitreihendaten ist das R^2 tendenziell immer höher als bei Querschnitts- oder Paneldaten

Bitte fixieren Sie sich in ihrer Interpretation nicht auf das R^2 !

Erkenntnisse aus der Regressionstabelle

Interessanter: Der geschätzte Koeffizient zum `BIP-Wachstum` in Höhe von 0,09.

Wie kann dieser Koeffizient interpretiert werden?

Erkenntnisse aus der Regressionstabelle

Interessanter: Der geschätzte Koeffizient zum `BIP-Wachstum` in Höhe von 0,09.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höheres BIP Wachstum korrespondiert im Durchschnitt mit einer um 0,09 Prozentpunkte niedrigeren Arbeitslosenquote.

Erkenntnisse aus der Regressionstabelle

Interessanter: Der geschätzte Koeffizient zum `BIP-Wachstum` in Höhe von 0,09.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höheres BIP Wachstum korrespondiert im Durchschnitt mit einer um 0,09 Prozentpunkte niedrigeren Arbeitslosenquote.

Wie kann die Konstante interpretiert werden?

Erkenntnisse aus der Regressionstabelle

Interessanter: Der geschätzte Koeffizient zum `BIP-Wachstum` in Höhe von 0,09.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höheres BIP Wachstum korrespondiert im Durchschnitt mit einer um 0,09 Prozentpunkte niedrigeren Arbeitslosenquote.

Wie kann die Konstante interpretiert werden?

Die erwartete Arbeitslosenquote bei einem Wachstum von 0% liegt im Durchschnitt bei 5,68 Prozent.

Erkenntnisse aus der Regressionstabelle

Weitere wichtige Erkenntnis aus der Tabelle:

- + Der Koeffizient von `BIP-Wachstum` ist auf dem 10%-Niveau signifikant

Woran kann dies gesehen werden?

Erkenntnisse aus der Regressionstabelle

Weitere wichtige Erkenntnis aus der Tabelle:

- + Der Koeffizient von `BIP-Wachstum` ist auf dem 10%-Niveau signifikant

Woran kann dies gesehen werden?

Wie hoch ist die t-Statistik für unseren Koeffizienten `BIP-Wachstum`?

Erkenntnisse aus der Regressionstabelle

Weitere wichtige Erkenntnis aus der Tabelle:

- + Der Koeffizient von `BIP-Wachstum` ist auf dem 10%-Niveau signifikant

Woran kann dies gesehen werden?

Wie hoch ist die t-Statistik für unseren Koeffizienten `BIP-Wachstum`?

Landkreise mit einem höheren BIP Wachstum könnten neue Unternehmen angesiedelt haben, welche neue Mitarbeiter brauchen. Daher würde ein entsprechend negativer Zusammenhang zwischen BIP-Wachstum und Arbeitslosenquote unseren Erwartungen entsprechen.

Arbeitslosenquote auf öffentliche Schulden regressieren

```
schulden <- lm(alo_quote ~ anteil_schulden, data=gesamtdaten)

stargazer(schulden,
  type = "html", header = FALSE, digits = 2,
  title = "Arbeitslosigkeit auf Anteil der Schulden pro Landkreis",
  dep.var.labels=c("Alo-quote"),
  covariate.labels="Anteil der Schulden"
)
```

Arbeitslosenquote auf öffentliche Schulden regressieren

Arbeitslosigkeit auf Anteil der Schulden pro Landkreis

	<i>Dependent variable:</i>
	Alo-quote
Anteil der Schulden	0.25*** (0.02)
Constant	3.37*** (0.16)
Observations	397
R ²	0.35
Adjusted R ²	0.35
Residual Std. Error	1.91 (df = 395)
F Statistic	216.36*** (df = 1; 395)
Note:	* p<0.1; ** p<0.05; *** p<0.01

Erkenntnisse aus der Regressionstabelle

Der geschätzte Koeffizient zum Anteil der öffentlichen Schulden liegt bei 0,25.

Wie kann dieser Koeffizient interpretiert werden?

Erkenntnisse aus der Regressionstabelle

Der geschätzte Koeffizient zum Anteil der öffentlichen Schulden liegt bei 0,25.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höhere Verschuldung korrespondiert im Durchschnitt mit einer um 0,25 Prozentpunkte höheren Arbeitslosenquote

Erkenntnisse aus der Regressionstabelle

Der geschätzte Koeffizient zum Anteil der öffentlichen Schulden liegt bei 0,25.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höhere Verschuldung korrespondiert im Durchschnitt mit einer um 0,25 Prozentpunkte höheren Arbeitslosenquote

Die Interpretation der Konstante wäre dann wie folgt:

Für einen Landkreis ohne Verschuldung wäre die erwartete Arbeitslosenquote im Durchschnitt bei 3,37 Prozent.

Erkenntnisse aus der Regressionstabelle

Der geschätzte Koeffizient zum Anteil der öffentlichen Schulden liegt bei 0,25.

Wie kann dieser Koeffizient interpretiert werden?

Eine um 1 Prozentpunkt höhere Verschuldung korrespondiert im Durchschnitt mit einer um 0,25 Prozentpunkte höheren Arbeitslosenquote

Die Interpretation der Konstante wäre dann wie folgt:

Für einen Landkreis ohne Verschuldung wäre die erwartete Arbeitslosenquote im Durchschnitt bei 3,37 Prozent.

Ein stark verschuldeter öffentlicher Haushalt hat potentiell weniger Gewerbeeinnahmen und da dort potentiell weniger Unternehmen vorhanden sind in denen Arbeitnehmer angestellt sein könnten.

Multiple linear Regression

Multiple lineare Regression

- ✚ Sowohl das BIP Wachstum, als auch die öffentliche Verschuldung sind wichtige Faktoren zur Erklärung der Arbeitslosenquote
- ✚ Öffentliche Verschuldung schien wichtiger zu sein, doch können wir beide Variablen in EINE Regression aufnehmen?

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i, i = 1, \dots, N$$

- ✚ Durch die multiple lineare Regression können wir den Effekt einer unabhängigen Variablen auf die abhängige Variable untersuchen und zusätzlich auf den Effekt anderer Variablen **kontrollieren**.
- ✚ Konkret: BIP-Wachstum und öffentliche Verschuldung in eine Regression packen!

Multiple linear Regression

```
multi <- lm(alo_quote ~ anteil_schulden + bip_wachstum, data=gesamtdaten)

stargazer(multi,
  type = "html", header = FALSE, digits = 2,
  title = "Arbeitslosigkeit auf Anteil Schulden und BIP-Wachstum",
  dep.var.labels=c("Alo-quote"),
  covariate.labels=c("Anteil der Schulden", "BIP-Wachstum")
)
```

Multiple linear Regression

Arbeitslosigkeit auf Anteil Schulden und BIP-Wachstum

	<i>Dependent variable:</i>
	Alo-quote
Anteil der Schulden	0.25 ^{***} (0.02)
BIP-Wachstum	0.001 (0.04)
Constant	3.37 ^{***} (0.24)
Observations	397
R ²	0.35
Adjusted R ²	0.35
Residual Std. Error	1.91 (df = 394)
F Statistic	107.90 ^{***} (df = 2; 394)
Note:	* p<0.1; ** p<0.05; *** p<0.01

Multiple linear Regression

Arbeitslosigkeit auf Anteil Schulden und BIP-Wachstum

	<i>Dependent variable:</i>
	Alo-quote
Anteil der Schulden	0.25 ^{***} (0.02)
BIP-Wachstum	0.001 (0.04)
Constant	3.37 ^{***} (0.24)
Observations	397
R ²	0.35
Adjusted R ²	0.35
Residual Std. Error	1.91 (df = 394)
F Statistic	107.90 ^{***} (df = 2; 394)

Note: * p<0.1; ** p<0.05; *** p<0.01

- + Varianz wird zum Größten Teil durch die öffentlichen Schulden erklärt
- + Schätzer für die Verschuldung bleibt in Höhe und Signifikanz bestehen
- + BIP-Wachstum nicht mehr signifikant und Koeffizient deutlich kleiner

Sample Splits und Interaktionsmodell

Sample Splits und Interaktionsmodell

Durch die deskriptive Analyse wissen wir, dass es große Unterschiede zwischen ost- und westdeutschen Landkreisen gibt (und das in allen untersuchten Dimensionen).

Gilt der dokumentierte Zusammenhang zwischen dem Anteil der öffentlichen Verschuldung und der Arbeitslosenquote für Ost- und Westdeutschland gleichermaßen?

Sample Splits und Interaktionsmodell

Durch die deskriptive Analyse wissen wir, dass es große Unterschiede zwischen ost- und westdeutschen Landkreisen gibt (und das in allen untersuchten Dimensionen).

Gilt der dokumentierte Zusammenhang zwischen dem Anteil der öffentlichen Verschuldung und der Arbeitslosenquote für Ost- und Westdeutschland gleichermaßen?

Um dieser Frage auf den Grund zu gehen wollen wir im ersten Schritt die Variable `Ostdeutschland` in unserer Regression hinzufügen:

```
schulden <- lm(alo_quote ~ anteil_schulden + ost, data=gesamtdaten)

stargazer(schulden,
  type = "html", header = FALSE, digits = 2,
  title = "Arbeitslosigkeit mit Interaktionstermen",
  dep.var.labels=c("Alo-quote"),
  covariate.labels=c("Anteil Schulden", "Ostdeutschland")
)
```

Sample Splits und Interaktionsmodell

Arbeitslosigkeit mit Interaktionstermen	
	<i>Dependent variable:</i>
	Alo-quote
Anteil Schulden	0.22 ^{***} (0.02)
Ostdeutschland	2.04 ^{***} (0.23)
Constant	3.20 ^{***} (0.15)
Observations	397
R ²	0.46
Adjusted R ²	0.46
Residual Std. Error	1.74 (df = 394)
F Statistic	170.86 ^{***} (df = 2; 394)
Note:	* p<0.1; ** p<0.05; *** p<0.01

Sample Splits und Interaktionsmodell

Arbeitslosigkeit mit Interaktionstermen	
	<i>Dependent variable:</i>
	Alo-quote
Anteil Schulden	0.22 ^{***} (0.02)
Ostdeutschland	2.04 ^{***} (0.23)
Constant	3.20 ^{***} (0.15)
Observations	397
R ²	0.46
Adjusted R ²	0.46
Residual Std. Error	1.74 (df = 394)
F Statistic	170.86 ^{***} (df = 2; 394)
Note: * p<0.1; ** p<0.05; *** p<0.01	

- + `Ostdeutschland` ist eine Dummyvariable, welche 1 ist für alle ostdeutschen Landkreise
- + In ostdeutschen Landkreisen ist die Arbeitslosigkeit im Durchschnitt um 2.04 Prozentpunkte höher als in westdeutschen Landkreisen
- + Koeffizient signifikant auf dem 1%-Signifikanzniveau
- + Höheres R² (Varianz in der Alo-quote kann besser erklärt werden)
- + Keine Auswirkung auf den Koeffizienten der öffentlichen Verschuldung

Sample Splits und Interaktionsmodell

Diese Regression beantwortet jedoch nicht genau unsere Frage!

- + Wir wollten wissen, ob der Zusammenhang zwischen öffentlicher Verschuldung und Arbeitslosenquote für alle ost- und westdeutschen Landkreise gleichermaßen gilt

Dafür müssen wir die Variable `Ostdeutschland` mit der Variablen `Anteil_Schulden` **interagieren!**

Sample Splits und Interaktionsmodell

```
schulden <- lm(alo_quote ~ anteil_schulden + ost, data=gesamtdaten)
ost <- lm(alo_quote ~ anteil_schulden, data=filter(gesamtdaten, ost==1))
west <- lm(alo_quote ~ anteil_schulden, data=filter(gesamtdaten, ost==0))
interaktion <- lm(alo_quote ~ anteil_schulden*ost, data=gesamtdaten)

stargazer(schulden, interaktion, west, ost,
  type = "html", header = FALSE, digits = 2,
  title = "Arbeitslosigkeit mit Interaktionstermen",
  dep.var.labels=c("Alo-quote"),
  covariate.labels=c("Anteil Schulden", "Ostdeutschland", "Anteil Schulden * Ostdeutschland")
)
```

Sample Splits und Interaktionsmodell

Arbeitslosigkeit mit Interaktionstermen				
	Dependent variable:			
	Alo-quote			
	(1)	(2)	(3)	(4)
Anteil Schulden	0.22*** (0.02)	0.23*** (0.02)	0.23*** (0.02)	0.05 (0.07)
Ostdeutschland	2.04*** (0.23)	3.82*** (0.68)		
Anteil Schulden * Ostdeutschland		-0.18*** (0.07)		
Constant	3.20*** (0.15)	3.12*** (0.15)	3.12*** (0.15)	6.95*** (0.76)
Observations	397	397	321	76
R ²	0.46	0.47	0.41	0.01
Adjusted R ²	0.46	0.47	0.41	-0.01
Residual Std. Error	1.74 (df = 394)	1.72 (df = 393)	1.66 (df = 319)	1.96 (df = 74)
F Statistic	170.86*** (df = 2, 394)	118.41*** (df = 3, 393)	221.84*** (df = 1, 319)	0.57 (df = 1, 74)

Sample Splits und Interaktionsmodell

Wie können Sie den Interaktionsterm interpretieren?

Sample Splits und Interaktionsmodell

Wie können Sie den Interaktionsterm interpretieren?

- + Spalte 2 repräsentiert das Interaktionsmodell
- + In Spalte 3 und 4 wurden separate Regressionen für alle westdeutschen (Spalte 3) und ostdeutschen (Spalte 4) Landkreise durchgeführt
- + Analyse von Spalte 2 im Zusammenspiel mit Spalte 3 und 4 erleichtert das Verständnis für die Interaktionsvariable

Sample Splits und Interaktionsmodell

Wie können Sie den Interaktionsterm interpretieren?

- + Spalte 2 repräsentiert das Interaktionsmodell
- + In Spalte 3 und 4 wurden separate Regressionen für alle westdeutschen (Spalte 3) und ostdeutschen (Spalte 4) Landkreise durchgeführt
- + Analyse von Spalte 2 im Zusammenspiel mit Spalte 3 und 4 erleichtert das Verständnis für die Interaktionsvariable
- + **Konstante:**
 - + In Spalte 3 (für Westdeutsche) bei 3.12, was dem Wert aus Spalte 2 (Interaktionsmodell) entspricht.
 - + In Spalte 4 (für Ostdeutsche) bei 6.95
 - + Die durchschnittliche Arbeitslosenquote für einen unverschuldeten ostdeutschen Landkreis liegt deutlich höher als bei einem westdeutschen (3.12 Prozent vs. 6.95 Prozent)

Dieses Ergebnis bekommen wir auch aus dem Interaktionsmodell!

→ Dummy Variable `Ostdeutschland` und die Konstante aufaddieren: $\text{Ostdeutschland} + \text{Constant} = 3.82 + 3.12 = 6.94$ (Achtung: Rundung)!

Sample Splits und Interaktionsmodell

+ Anteil Schulden:

- + In Spalte 3 (für Westdeutsche) bei 0.23, was dem Wert aus Spalte 2 (Interaktionsmodell) entspricht
- + In Spalte 4 (für Ostdeutsche) ist der Zusammenhang deutlich kleiner und insignifikant
- + Für alle westdeutschen Landkreise gibt es einen signifikanten Zusammenhang zwischen der öffentlichen Verschuldung und der Arbeitslosenquote
- + Direkt ersichtlich das der Zusammenhang für ostdeutsche Landkreise signifikant kleiner ist als für westdeutsche (um -0.18 Prozentpunkte, der Koeffizient von `Anteil Schulden * Ostdeutschland`)

→ Wenn wir uns den Zusammenhang für alle ostdeutschen Landkreise berechnen möchten, dann ergibt sich dieser als $\text{Anteil Schulden} + \text{Anteil Schulden} * \text{Ostdeutschland} = 0.23 + (-0.18) = 0.05$

Die westdeutschen Landkreise dienen uns hier überall als Basislevel!

Sample Splits und Interaktionsmodell

+ Anteil Schulden:

- + In Spalte 3 (für Westdeutsche) bei 0.23, was dem Wert aus Spalte 2 (Interaktionsmodell) entspricht
- + In Spalte 4 (für Ostdeutsche) ist der Zusammenhang deutlich kleiner und insignifikant
- + Für alle westdeutschen Landkreise gibt es einen signifikanten Zusammenhang zwischen der öffentlichen Verschuldung und der Arbeitslosenquote
- + Direkt ersichtlich das der Zusammenhang für ostdeutsche Landkreise signifikant kleiner ist als für westdeutsche (um -0.18 Prozentpunkte, der Koeffizient von `Anteil Schulden * Ostdeutschland`)

→ Wenn wir uns den Zusammenhang für alle ostdeutschen Landkreise berechnen möchten, dann ergibt sich dieser als $\text{Anteil Schulden} + \text{Anteil Schulden} * \text{Ostdeutschland} = 0.23 + (-0.18) = 0.05$

Die westdeutschen Landkreise dienen uns hier überall als Basislevel!

Vorteil des Interaktionsmodells:

Durch das Interaktionsmodell nutzen wir **eine** Regression und verwenden den kompletten Datensatz, dadurch hat unsere Regression mehr Power um Effekte zu finden.

Sind diese Ergebnisse *kausal* zu
interpretieren?

Sind diese Ergebnisse *kausal* zu interpretieren?

- ✚ Basieren auf Beobachtungsdaten
- ✚ Arbeitslosenquote könnte noch von vielen anderen Faktoren beeinflusst sein, welche wir hier nicht aufgenommen haben (z.B. der Bevölkerungszuwachs oder die Inflation)
- ✚ Um kausale Effekte messen zu können müssten wir entweder ein kontrolliert randomisiertes Experiment durchführen oder uns ein natürliches Experiment in den Daten zunutze machen

Kausale Antworten auf verschiedenste Fragen wollen wir in den folgenden Vorlesungseinheiten auf der Basis anderer Datensätze tätigen.

Zusammenfassung

Was haben wir über die Arbeitslosenquote in Deutschland gelernt?

- + Es gibt starke regionale Unterschiede in Deutschland
- + Der Anteil der öffentlichen Schulden scheint ein wichtiger Faktor zur Vorhersage der Arbeitslosenquote zu sein
- + Eine fundierte deskriptive Analyse schafft die Grundlage für eine spätere fundierte tiefergehende Analyse mittels linearer Regression

Übungsaufgaben

Im ersten Teil der Case Study hatten Sie sich noch die durchschnittlichen Einkommen auf Landkreisebene in R eingelesen und im zweiten Teil deskriptiv untersucht. Nun sollten Sie diese Tabelle mittels linearer Regression analysieren:

- + Erstellen Sie eine Regressionstabelle mittels `stargazer` in der Sie die Arbeitslosenquote auf die Einkommen für das Jahr 2017 regressieren.
 - + Interpretieren Sie ihre Ergebnisse
- + Erstellen Sie ein Interaktionsmodell incl. Sample Split mittels `stargazer` und interpretieren Sie die Ergebnisse ihrer Regressionen.